

Assurances : veille stratégique

Mise en place de la base de données

par Tiphane RONE
30.10.2024



Quelle a été la méthode pour structurer les données brutes et nous permettre de les interroger?

- 1 **Préparation** : dictionnaire de données
- 2 **Structuration** : schéma de la Base De Données (BDD)
- 3 **Mise en place de la base de données**
- 4 **Exploitation des données** : requêtes et analyse

Préparation : dictionnaire de données

Avec Microsoft Excel

A

B

C

D

E

F

Table 1:
Table de fait

Nb lignes : 30 335
(sans en-tête)

CONTRAT.CSV

Nom des colonnes	Type de données	Taille	NON-NULL?	Clé	Description
Contrat_ID	INT		NON-NULL	Clé primaire	Id unique pour les contrats
No_voie	INT				Numéro dans la voie pour l'adresse du logement assuré
B_T_Q	VARCHAR	1			Bis, Ter, Quarter: Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
Type_de_voie	VARCHAR	4			Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
Voie	VARCHAR	26	NON-NULL		Libellé de la voie pour l'adresse du logement assuré
Code_dep_code_commune	VARCHAR	6	NON-NULL	Clé étrangère	Concaténation du code département et code commune pour avoir une clé unique
Code_postal	INT				Code postal pour l'adresse du logement assuré
Surface	INT		NON-NULL		Nombre de pièces
Type_local	VARCHAR	11	NON-NULL		Indique si c'est un appartement ou une maison
Occupation	VARCHAR	12	NON-NULL		Indique si l'occupant est le propriétaire ou un locataire
Type_contrat	VARCHAR	20	NON-NULL		Indique si le contrat d'assurance est pour une résid princip, secondaire ou pour mise en location
Formule	VARCHAR	9	NON-NULL		Indique si la couverture d'assurance est classique ou intégrale
Valeur_declaree_biens	VARCHAR	12	NON-NULL		Indique la valeur des biens pris en charge par l'assurance
Prix_cotisation_mensuel	INT		NON-NULL		Prix cotisation mensuelle de l'assurance (supposé en euros?)
Code_dep_code_commune	VARCHAR	6	NON-NULL	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
reg_code	INT		NON-NULL		Code de région
reg_nom	VARCHAR	26	NON-NULL		Nom de région
aca_nom	VARCHAR	24	NON-NULL		villes principales / aires d'attraction des villes
dep_nom	VARCHAR	43	NON-NULL		Nom de département
com_nom_maj_court	VARCHAR	32	NON-NULL		Nom de commune en majuscule
dep_code	VARCHAR	3	NON-NULL		Numéro de département
dep_nom_num	VARCHAR	49	NON-NULL		Nom de département et numéro de département

REGION.CSV

Table 2:
Table de dimension

Nb lignes : 38 916
(sans en-tête)

Issu des tables

Déterminés à l'aide de
tableaux croisés
dynamiques et filtres

Clés étaient déjà indiquées.
Sinon, check unicité, valeurs
non vides, test de colonnes...

Déduite à partir du nom de colonne ou valeurs prises

Schéma de la structure de la BDD

Avec SQL Power Architect


1

Exemple de schématisation d'une table:

Nom de la table
Clé Primaire = Primary key = PK (un ou plusieurs attributs)
Liste des attributs avec contraintes de type et permission de nullité (+ Clé étrangère: Foreign key = FK)

2

Schématisation de nos deux tables:



3


Requête générée pour créer la table

```
1 CREATE TABLE p3_assurance.Region (  
2     Code_dep_code_commune VARCHAR(6) NOT NULL,  
3     reg_code INTEGER NOT NULL,  
4     reg_nom VARCHAR(26) NOT NULL,  
5     aca_nom VARCHAR(24) NOT NULL,  
6     dep_nom VARCHAR(43) NOT NULL,  
7     com_nom_maj_court VARCHAR(32) NOT NULL,  
8     dep_code VARCHAR NOT NULL,  
9     dep_nom_num VARCHAR(49) NOT NULL,  
10    CONSTRAINT region_pk PRIMARY KEY (Code_dep_code_commune)  
11 );  
12  
13  
14  
15 CREATE TABLE p3_assurance.Contrat (  
16     Contrat_ID INTEGER NOT NULL,  
17     No_voie INTEGER,  
18     B_T_Q VARCHAR(1),  
19     Type_de_voie VARCHAR(4),  
20     Voie VARCHAR(26) NOT NULL,  
21     Code_dep_code_commune VARCHAR(6) NOT NULL,  
22     Code_postal INTEGER,  
23     Surface INTEGER NOT NULL,  
24     Type_local VARCHAR(11) NOT NULL,  
25     Occupation VARCHAR(12) NOT NULL,  
26     Type_contrat VARCHAR(20) NOT NULL,  
27     Formule VARCHAR(9) NOT NULL,  
28     Valeur_declaree_biens VARCHAR(12) NOT NULL,  
29     Prix_cotisation_mensuel INTEGER NOT NULL,  
30     CONSTRAINT contrat_pk PRIMARY KEY (Contrat_ID)  
31 );  
32  
33  
34 ALTER TABLE p3_assurance.Contrat ADD CONSTRAINT region_contrat_fk  
35 FOREIGN KEY (Code_dep_code_commune)  
36 REFERENCES p3_assurance.Region (Code_dep_code_commune)  
37 ON DELETE NO ACTION  
38 ON UPDATE NO ACTION  
39 NOT DEFERRABLE;  
40
```

Créeé pour PostgreSQL

Chargement de la base de données

Avec PG Admin 4 & PostgreSQL



1

Création de la BDD :
projet_opc

2

Création du schéma :
p3_assurance

3

Création des tables vides, attributs et lien clé à
l'aide du script généré, en faisant une requête.


4

Liaison des données aux tables vides créées : import des données



5

Vérification du bon chargement des données : nombre de lignes



contrat


✓ Table rows counted: 30335 ✗

region

✓ Table rows counted: 38916 ✗

6

Vérification du bon chargement des données : affichage premières lignes



contrat

	contrat_id [PK] integer	no_voie integer	b_t_q character varying (1)	type_de_voie character varying (1)
1	100601	190	A	RUE
2	100602	347	[null]	RUE
3	100603	58	[null]	AV
4	100604	140	[null]	RUE

region

code_dep_code_commune [PK] character varying (6)	reg_code integer	reg_nom character varying (26)
10001	44	Grand Est
10002	44	Grand Est
10003	44	Grand Est
10004	44	Grand Est

Requêtes 1, 2, 3

Avec PG Admin 4 & PostgreSQL

Requêtes

1

Lister les numéros de contrats (contrat_ID) avec leur surface pour la commune de Caen.

1	SELECT		
2	c.contrat_id,		
3	c.surface,		
4	r.com_nom_maj_court		
5	FROM p3_assurance.contrat AS c		
6	JOIN p3_assurance.region AS r		
7	ON c.code_dep_code_commune=r.code_dep_code_commune		
8	WHERE r.com_nom_maj_court='CAEN';		
	contrat_id	surface	com_nom_maj_court
	integer	integer	character varying (32)
1	103791	35	CAEN
2	103792	99	CAEN
3	103793	40	CAEN
4	103794	20	CAEN

2

Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

1	SELECT			
2	c.contrat_id,			
3	c.type_contrat,			
4	c.formule,			
5	c.type_local,			
6	r.dep_code			
7	FROM p3_assurance.contrat AS c			
8	JOIN p3_assurance.region AS r			
9	ON c.code_dep_code_commune=r.code_dep_code_commune			
10	WHERE			
11	c.type_local='Maison'			
12	AND r.dep_code='71';			
	contrat_id	type_contrat	formule	type_local
	integer	character varying (20)	character vary	character varyir
				dep_coc
				character
	114768	Residence principale	Integral	Maison
	114779	Residence principale	Classique	Maison
	114782	Residence principale	Classique	Maison
	114812	Residence principale	Integral	Maison

3

Lister le nom des régions de France.

1	SELECT DISTINCT reg_nom	
2	FROM p3_assurance.region;	
	reg_nom	
	character varying (26)	
1	Hauts-de-France	
2	La Réunion	
3	Bretagne	
4	Mayotte	
5	Auvergne-Rhône-Alpes	
6	Ile-de-France	
7	Grand Est	
8	Corse	
9	Collectivités d'outre-mer	
10	Guyane	
11	Bourgogne-Franche-Comté	
12	Provence-Alpes-Côte d'Azur	
13	Martinique	
14	Guadeloupe	
15	Normandie	
16	Nouvelle-Aquitaine	
17	Occitanie	
18	Pays de la Loire	
19	Centre-Val de Loire	

Explications

- **SELECT** : sélection des colonnes
- **AS** : aliasing (renommage)
- **FROM** : choix de table de gauche
- **JOIN** (inner) : pour faire appel à table Region et afficher les lignes de *contrat* qui ont des correspondances dans *region*
- **ON** : faire le lien entre les deux tables
- **WHERE** : condition sur les lignes de la table obtenue après le JOIN
- **DISTINCT** : pour avoir les valeurs distinctes/uniques de la colonne sélectionnée.

Requêtes 4, 5, 6 Avec PG Admin 4 & PostgreSQL

• Requêtes

4

Lister les 5 contrats avec les surfaces les + élevées.

```
1 SELECT
2   contrat_id,
3   surface
4 FROM p3_assurance.contrat
5 ORDER BY surface DESC
6 LIMIT 5;
```

	contrat integer	surface integer
1	104211	815
2	105463	742
3	130878	595
4	100822	570
5	109872	559

5

Prix moyen de la cotisation mensuelle

```
1 SELECT ROUND(AVG(prix_cotisation_mensuel),2) AS prix_moyen_cotisation_mensuel
2 FROM p3_assurance.contrat;
```

	prix_moyen_cotisation_mensuel numeric
1	19.33

6

Quel est le nombre de contrats pour chaque catégorie de prix de la valeur déclarée des biens ?


```
1 SELECT
2   valeur_declaree_biens,
3   COUNT (*) AS nombre_de_contrat
4 FROM p3_assurance.contrat
5 GROUP BY valeur_declaree_biens
6 ORDER BY valeur_declaree_biens;
```

	valeur_declaree_biens character varying (12)	nombre_de_contrat bigint
1	0-25000	22720
2	100000+	104
3	25000-50000	6815
4	50000-100000	696

=> Les contrats sont en majorité pour la catégorie de valeur la plus petite

• Explications

- **ORDER BY ... DESC** : trie la table dans l'ordre décroissant de la colonne spécifiée (ici, colonne surface)
- **LIMIT** : afficher les n premières lignes de la table ou du rendu de la table
- **ROUND**: fonction d'agrégation pour arrondir un nombre selon spécifié
- **AVG** : fonction d'agrégation pour calculer la moyenne d'une colonne
- **GROUP BY**: regrouper les enregistrements par même valeur selon colonne désignée.
- **COUNT(*)** utilisé conjointement avec **GROUP BY**: compte le nombre d'enregistrements dans chaque sous-groupe créé par GROUP BY.



Requêtes 7, 8, 9

Avec PG Admin 4 & PostgreSQL

• Requêtes

7

Quel est le nombre de formules “integral” sur la région Pays de la Loire ?

```
1 SELECT
2   r.reg_nom,
3   COUNT(*) AS nombre_formule_integral
4 FROM p3_assurance.contrat AS c
5 JOIN p3_assurance.region AS r
6 ON c.code_dep_code_commune=r.code_dep_code_commune
7 WHERE
8   c.formule = 'Integral'
9   AND r.reg_nom = 'Pays de la Loire'
10 GROUP BY r.reg_nom;
```

	reg_nom character varying (26) 🔒	nombre_formule_integral bigint 🔒
1	Pays de la Loire	589

8

Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

>> voir requête 2.

9

Quelle est la surface moyenne des contrats à Paris ?

```
1 SELECT
2   ROUND(AVG(c.surface),2) AS surface_moyenne,
3   r.dep_code
4 FROM p3_assurance.contrat AS c
5 JOIN p3_assurance.region AS r
6 ON c.code_dep_code_commune=r.code_dep_code_commune
7 WHERE r.dep_code='75'
8 GROUP BY r.dep_code;
```

	surface_moyenne numeric 🔒	dep_code character varying 🔒
1	51.77	75

• Explications

- **SELECT** : sélection des colonnes
- **AS** : aliasing (renommage)
- **FROM** : choix de table de gauche
- **JOIN** (inner) : pour faire appel à table Region et afficher les lignes de *contrat* qui ont des correspondances dans *region*
- **ON** : faire le lien entre les deux tables
- **WHERE** : condition sur les lignes de la table obtenue après le JOIN
- **DISTINCT** : pour avoir les valeurs distinctes/uniques de la colonne sélectionnée.

Requêtes 10, 11, 12 Avec PG Admin 4 & PostgreSQL

Requêtes

10

Classement des 10 départements où le prix moyen de la cotisation est le plus élevé.

```
1 SELECT
2   r.dep_code,
3   ROUND(AVG(c.prix_cotisation_mensuel),2) AS prix_moyen
4 FROM p3_assurance.contrat AS c
5 JOIN p3_assurance.region AS r
6 ON c.code_dep_code_commune=r.code_dep_code_commune
7 GROUP BY r.dep_code
8 ORDER BY prix_moyen DESC
9 LIMIT 10;
```

	dep_code character varying	prix_moyen numeric
1	75	36.40
2	92	26.27
3	94	19.82
4	78	18.89
5	69	18.49
6	1	18.24
7	6	18.14
8	17	17.32
9	74	17.15
10	2A	17.07

Explications

- HAVING** permet de filtrer les lignes d'un tableau agrégé (WHERE filtre avant l'agrégation donc impossible à utiliser)

11

Liste des communes ayant eu au moins 150 contrats.

```
1 SELECT
2   r.com_nom_maj_court AS commune,
3   COUNT(*) AS nombre_contrat
4 FROM p3_assurance.contrat AS c
5 JOIN p3_assurance.region AS r
6 ON c.code_dep_code_commune=r.code_dep_code_commune
7 GROUP BY commune
8 HAVING COUNT(*)>=150 -- on ne peut pas mettre un WHERE après une agrégation.
9 ORDER BY COUNT(*) DESC; -- optionnel
```

	commune character varying (32)	nombre_contrat bigint
1	PARIS 18	515
2	PARIS 17	468
3	PARIS 15	407
4	PARIS 16	394
5	NICE	387
6	PARIS 11	381
7	BORDEAUX	302
8	PARIS 20	302
9	NANTES	291
10	PARIS 19	266
11	PARIS 10	263
12	PARIS 12	252
13	PARIS 14	222
14	GRENOBLE	220
15	PARIS 9	204
16	TOULOUSE	187
17	TOULON	170
18	COURBEVOIE	163
19	LILLE	161
20	PARIS 3	159

12

Quel est le nombre de contrats pour chaque région ?

```
1 SELECT
2   r.reg_nom,
3   COUNT(*) AS nombre_de_contrat
4 FROM p3_assurance.contrat AS c
5 JOIN p3_assurance.region AS r
6 ON c.code_dep_code_commune=r.code_dep_code_commune
7 GROUP BY r.reg_nom
8 ORDER BY reg_nom;
```

	reg_nom character varying (26)	nombre_de_contrat bigint
1	Auvergne-Rhône-Alpes	3042
2	Bourgogne-Franche-Comté	293
3	Bretagne	947
4	Centre-Val de Loire	598
5	Corse	247
6	Grand Est	769
7	Guyane	37
8	Hauts-de-France	1189
9	Ile-de-France	14177
10	La Réunion	17
11	Martinique	73
12	Normandie	824
13	Nouvelle-Aquitaine	2038
14	Occitanie	1609
15	Pays de la Loire	1196
16	Provence-Alpes-Côte d'Azur	3279

ORDER BY COUNT(*) DESC

	reg_nom character varying (26)	nombre_de_contrat bigint
1	Ile-de-France	14177
2	Provence-Alpes-Côte d'Azur	3279
3	Auvergne-Rhône-Alpes	3042
4	Nouvelle-Aquitaine	2038
5	Occitanie	1609
6	Pays de la Loire	1196
7	Hauts-de-France	1189
8	Bretagne	947
9	Normandie	824
10	Grand Est	769
11	Centre-Val de Loire	598
12	Bourgogne-Franche-Comté	293
13	Corse	247
14	Martinique	73
15	Guyane	37
16	La Réunion	17



⇒ Majorité des contrats en Île-de-France
⇒ endroit où les prix sont en moyenne plus chers

Conclusion

- Dictionnaire de données
- Schéma relationnel
- Mise en place de la BDD
- Requêtes SQL
- Analyses

Merci.

Tiphanie RONEl

Requêtes supplémentaires

Avec PG Admin 4 & PostgreSQL

- Requêtes

13

Lister les numéros de contrats (contrat_id) avec leur surface pour le code postal 92100

```
1 SELECT
2   contrat_id,
3   surface,
4   code_postal
5 FROM p3_assurance.contrat AS c
6 JOIN p3_assurance.region AS r
7 ON c.code_dep_code_commune=r.code_dep_code_commune
8 WHERE code_postal='92100'
9 ORDER BY contrat_id;
```

	contrat_id [PK] integer	surface integer	code_postal integer
1	123026	61	92100
2	123027	31	92100
3	123028	17	92100
4	123030	78	92100
5	123032	109	92100
6	123033	87	92100
7	123034	80	92100
8	123035	70	92100
9	123036	51	92100
10	123037	24	92100
11	123040	150	92100
12	123041	16	92100
13	123042	66	92100
14	123043	39	92100
15	123044	100	92100
84	123178	64	92100
85	123180	31	92100
86	123181	37	92100
87	123183	67	92100
88	123185	63	92100

14

Combien existe-t-il de contrats sur les résidences principales?

```
1 SELECT
2   COUNT(*) AS nombre_de_contrat,
3   type_contrat
4 FROM p3_assurance.contrat AS c
5 WHERE type_contrat='Residence principale'
6 GROUP BY type_contrat
```

	nombre_de_contrat bigint	type_contrat character varying (20)
1	25620	Residence principale