

Analyse commerciale

Tiphanie R. – Data analyst

LAPAGE



Sommaire

- 1 Contexte
- 2 Indicateurs généraux de ventes
- 3 Focus Client



Contexte

Contexte

Besoin

- Au départ, **entreprise physique** → + ouverture e-commerce il y a 2 ans
- **Faire le point** sur l'activité en ligne
- **Recommandations** : adaptation des offres, prix, public cible...

Deux analyses


- Analyse **commerciale globale**
- Analyse ciblée **comportement client**

Suite aux analyses, étape suivante

→ **Comparer** avec librairie physique



Environnement pour réaliser les analyses



Trois sources à notre disposition : Customers, Products, Transactions

	Tableau format CSV	Source	Description	Périmètre temporel	Nettoyage du fichier	Données sensibles?
1	Customers	Site web	Infos clients : identifiant, genre, année de naissance	-	Fichier pré-nettoyé	non
2	Products	Site web	Infos produits : identifiant, prix, catégorie (0, 1, ou 2)	-	Fichier pré-nettoyé	non
3	Transactions	Site web	Liste transactions : produit, date d'achat, session, client	Mars 2021 à février 2023	Fichier pré-nettoyé Lignes vides Conversion de date	non

Croisement des données à 100% 


*CSV : Comma Separated Values (format de fichier)

Indicateurs généraux de ventes

Offre diversifiée : transaction à prix médian de 14 € avec haut de gamme à 300 €


1

Répartition des prix (€)



2

Répartition des prix (€) par catégorie




Graphique n°1 : Répartition des prix

- Stratégie commerciale large : gamme complète allant jusqu'à 300€
- Toute période : 50% des produits achetés ont un prix entre 9€ et 19€

Graphique n°2 : Répartition des prix par catégories


- Catégorie 0 : Prix grand public
- Catégorie 1 : Prix moyen de gamme
- Catégorie 2 : Prix haut de gamme

De la performance à un CA qui se stabilise ?



La catégorie 1 est leader en termes de CA : 40% du CA au global...


1



Graphique n°1

Chaque catégorie contribue significativement au CA.


2



Graphique n°2


- Avant 2022 : phase d'initialisation, tests, mise en avant des produits...
- Depuis février 2022, tendance à la stabilisation : 0 et 1 restent au-dessus
- Données lissées à certains endroits ? 2021-10 (catégories 0 et 2), 2022-01 (2)

...mais la catégorie 0 est la plus forte en volume : 60 % des produits vendus au global.



Graphique n°1

Catégorie 2 est faible en termes de volume (5%) mais pour rappel : 23% de CA




Graphique n°2

Tendances similaires au fil des ans

100 % du Top 5 des bestsellers a franchit les 2 000 ventes


1



Graphique n°1

- Produits de catégorie 1
- Qté vendue : +2000


2



Graphique n°2


- 2021, 2022 : mêmes produits
- 2023, 2 nouveaux : 1_412 et 1_406

Certains produits vendus 1 à 2 fois au global, en majorité dans la catégorie 0




↓

Catégories 0 et 2



↓

Majorité catégorie 0



↓


Trois catégories.
Majorité catégorie 0

→ Améliorer la visibilité des produits concernés ?

Une minorité de clients génère la majorité du CA

Distribution des ventes au sein des clients

1




Graphique n°1 : Courbe de Lorenz des ventes clients

- Forte courbure vers le bas
 - Quantification de l'inégalité avec l'indice de Gini [0;1]: 0.44
- Une minorité de clients génère la majorité du CA




2



Graphique n°2 : Dépenses totales par client

- Entouré en rouge, 4 points qui se démarquent
- → 4 clients avec chacun une dépense totale comprise entre 100K et 350K

Distribution des ventes au sein des clients pros




- Ces 4 clients représentent **7,35 % du CA total**, toute période.
- **C_1609** : Principalement 0 puis 1
- **C_3454** : Principalement 1 et 0
- **C_4958** : Principalement 2, un peu de 1
- **C_6714** : Un peu des 3 catégories

→ Attention aux clients **C_4958** et **C_1609** : dépendance ?

Focus Client (hors clients pros)

Méthodologie



Lien entre l'âge des clients et différentes variables

Matrice des corrélations Spearman

Tests possibles

- Quantitatif continu → Pearson vs. Spearman

Conditions observées

- Non linéarité entre les variables
- Distributions non normales
- Présence d'outliers

→ Spearman

Hypothèse de départ (H_0)

- Il n'existe aucune corrélation entre les variables ($\rho = 0$) avec $p \in [-1;1]$

Fiabilité statistique


- p-value très petit < 0,05 → Hypothèse H_0 rejetée

→ Il existe un lien monotone statistiquement significatif.

Résultats et observations

- Âge / Montant total des achats : $\rho = -0.18$ → lien faible négatif
- Âge / Fréquence d'achat : $\rho = 0.22$ → lien faible positif
- Âge / Panier moyen : $\rho = -0.33$ → lien faible négatif


→ Corrélations existantes faibles mais significatives




Le genre n'est pas un levier de différenciation dans le choix des produits

Lien entre genre et catégorie de produits achetés

1



2



Tests possibles

- Qualitatif → Fisher vs. Chi-2

Conditions observées

- Chaque individu appartient à une seule catégorie
- Echantillon de taille suffisante
- Effectifs attendus > 5

→ Test du Chi-2 d'indépendance.

Hypothèse de départ (H₀)

- Pas d'association entre genre et catégorie.

Fiabilité statistique

- p-value = 0,09 > 0,05 → Hypothèse H₀ non rejetée


→ Pas d'association significative entre genre et catégorie.

Résultats et observations


- Ecart global entre valeurs attendues et observées : Chi-2 = 4,80 → modéré
- → Pas de relation statistiquement significative entre genre et catégorie.

Lien existant entre l'âge des clients et la catégorie de produits achetés

1



2



Tests possibles

- Variables mixtes → ANOVA vs. Kruskal-Wallis

Conditions observées

- Non linéarité entre les variables
- Distributions non normales
- Chaque individu appartient à une seule catégorie
- Les mesures d'âge ne sont pas liées entre elles
- Variances inégales possibles

→ Kruskal-Wallis

Hypothèse de départ (H_0)

- Pas d'association entre âge et catégorie.

Fiabilité statistique

- $p\text{-value} = 0 < 0,05$ → Hypothèse H_0 rejetée

→ Il existe association significative entre âge et catégorie.

Résultats et observations

- Graphique N° 1 : Âges médians différents
- Graphique N°2 : pic marqué à 17 ans.
- Statistique H : 1968,5
- → Il existe une différence significative d'âge entre au moins deux catégories de produits.

Conclusion

- Méthodologie de construction du notebook
- Analyses et relations
 - Globales
 - Focus Client (sans les pros)





Merci.