

Algorithme de détection automatique de faux billets

Méthodologie et résultats

Tiphanie R. – Data analyst



Sommaire

- 1 Contexte et nettoyage des données
- 2 Analyse exploratoire
- 3 Sélection du meilleur modèle
- 4 Algorithme de détection de faux billets

Contexte et nettoyage des données

Contexte



Objectif

Construire un algorithme capable de différencier un vrai billet d'un faux, à partir de ses caractéristiques géométriques.

- Pour l'Organisation nationale de **lutte contre le faux-monnayage** (ONCFM), organisation **publique**
- Mission de l'organisme : mettre en place des méthodes **d'identification des contrefaçons** des **billets en euros**.

À disposition : 2 tables, 7 variables

Présentation des données

Dataset N°1

Pour analyse et apprentissage (données exemples)


1
Table

- Billet_production

7
Variables

- Margin_up, Margin_down
- Margin_left, Margin_right
- Diagonal, Length
- **Is_genuine** ←

1500
Lignes



Dataset N°2

Pour évaluation de l'algorithme final

1
Table

- Billet pour évaluation finale

7
Variables


- Margin_up, Margin_down
- Margin_left, Margin_right
- Diagonal, Length
- **Id** ←

5
Lignes

Répartition des billets ?
→ à déterminer

Nettoyage dataset N°1 : Imputation des 37 valeurs manquantes (margin_low)

Méthodologie : utilisation du modèle de régression linéaire




Nettoyage dataset N°1 : Imputation des 37 valeurs manquantes

Performance et résultats du modèle de régression linéaire


1. Test : Valeurs réelles vs. Valeurs « prédites »

Comparaison des distributions de margin_low : valeurs réelles vs prédictions



2. Valeurs observées vs. Valeurs imputées


Comparaison des distributions de margin_low :
Observée vs Imputée



Analyse exploratoire

Length et Margin_up : variables explicatives qui se démarquent le plus

Répartition des dimensions géométriques en fonction de la nature du billet dans le dataset N°1 (données exemples)



Height_left est la variable avec le plus d'outliers (11)

Identification des outliers

1. Méthode IQR (Interquatile Range)

On a :

Q1 : 1er quantile (0,25)

Q3 : 3^e quantile (0,75)

Calcul de l'écart interquartile

Écart interquartile IQR = $Q3 - Q1$


Calcul des seuils hauts et bas

Seuil haut = $Q3 + 1,5 * IQR$


Seuil bas = $Q1 - 1,5 * IQR$

2. Tableau récapitulatif des outliers

Variable	# Vrai	# Faux
margin_low	9	1
margin_up	5	1
length	5	4
height_left	4	7
height_right	9	1
diagonal	4	5



Les variables sont peu corrélées entre elles




Sélection du meilleur modèle


4 modèles utilisés : Régression logistique, Random Forest, KNN, Kmeans

Methodologie


Séparation du dataset corrigé




3 algorithmes de prédiction, supervisés



1 algorithme de clustering, non supervisé



« Donne-moi les indices, je te dirai de quel côté tu penches »




Le modèle de régression logistique est pertinent ☒

Construction du modèle

1. Réglage des paramètres du modèle

Nombre max d'itérations à 1000.
Suffisant pour convergence optimale.

2. Probabilités prédites




Billets considérés comme
probablement faux

Billets considérés comme
probablement vrais

Pics séparés → Modèle pertinent



« Demande à 1000
arbres de décisions
et prend l'avis
majoritaire »





Le modèle Random Forest Classifieur est pertinent ✓

Construction du modèle


1. Réglage des paramètres du modèle



2. Importance des variables



3. Probabilités prédites




Billets considérés comme
probablement faux

Billets considérés comme
probablement vrais

Pics séparés → Modèle pertinent


« Dis-moi qui
sont tes voisins,
je te dirais qui tu
es »



Le modèle KNN est pertinent ✓


Construction du modèle

1. Réglage des paramètres du modèle



→ Nombre de voisins k choisi : k=7

2. Probabilités prédites




Billets considérés comme
probablement faux

Billets considérés comme
probablement vrais

Pics séparés → Modèle pertinent

« Rapproche-toi du centre qui te ressemble le plus, et je le ferai bouger jusqu'à ce qu'on trouve vos familles. »




La pertinence du modèle Kmeans est limitée X

Construction du modèle

1. Point d'attention ⚠

- Kmeans regroupe simplement les données selon similarités.
- Ne dit pas automatiquement qui est vrai ou faux (association manuelle faite après entraînement).
- **Privilégier modèle supervisé.**

2. Méthode du coude pour vérifier le nombre de clusters



Chute entre 1 et 2 et après pente douce.

→ Il y a bien 2 clusters dominants.


→ Choisissons : Nombre de clusters = 2

3. Visualisation des clusters en 2D

6 variables → Impossible à visualiser directement en 2D → ACP pour réduire variables tout en conservant le plus d'infos.

a.


2 composantes suffisent à représenter fidèlement les données ?



→ 2 composantes suffisent à expliquer un peu plus de 60% de la variance.

b.


La séparation des groupes est-elle identique ?



Conclusion : Les deux graphiques sont très proches, K-means a bien séparé les deux groupes.


Choix final : Le modèle de régression logistique suffit à différencier un vrai billet d'un faux

Matrices de confusion



→ KNN moins fiable

Courbes ROC



Récapitulatif

--- Comparaison des modèles (valeurs maximales en vert) ---

	Accuracy	Précision	Rappel	F1-score	ROC-AUC
Modèle					
Régression Logistique	0.9933	0.9896	1.0000	0.9948	0.9999
KNN	0.9833	0.9744	1.0000	0.9870	0.9953
Random Forest	0.9933	0.9896	1.0000	0.9948	0.9999

→ Régression logistique et Random Forest ex-aequo

Mais le modèle le plus simple à mettre en place et le plus explicable est la régression logistique.

→ **Modèle retenu = régression logistique**

Algorithme de détection de faux billets

Script avec interface graphique

1

2

3

4

Détention de billets

Choisir CSV Lancer prédiction

billets_test.csv

margin_low	margin_up	length	height_left	height_right	diagonal	resultat	id
5.21	3.3	111.42	104.01	103.54	171.76	Faux billet	A 1
6.0	3.31	112.09	104.17	104.13	171.87	Faux billet	A 2
4.99	3.39	111.57	104.58	104.29	172.0	Faux billet	A 3
4.44	3.03	113.2	104.55	104.34	172.49	Vrai billet	A 4
3.77	3.16	113.33	103.63	103.56	171.65	Vrai billet	A 5

Vrais billets: 2 (40.0%) | Faux billets: 3 (60.0%)

Terminé

Résultats sauvegardés sous : script_output/resultats_predictions.csv

OK

```
load_file).pack(side=tk.LEFT, padx=5)
self.run_prediction_save_result).pack(side=tk.LEFT, padx=5)
ctionné")
```



Merci.